

# AGH

## **AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE**

Projekt 4

Ekonometria Finansowa i Dynamiczna

Maciej Nagły, Karol Kuciński, Mateusz Mulka

Informatyka i Ekonometria

II stopień, studia stacjonarne

## Spis treści

Wstęp .....	3
Przygotowanie danych oraz modelu VAR(1) .....	3
Badanie wpływu nie uwzględnienia heteroskedastyczności składników losowych na rozmiar testu przyczynowości Grangera w ramach modelu VAR .....	5
Wpływ długości danych .....	5
Wpływ siły heteroskedastyczności składników losowych .....	7
Wpływ siły autokorelacji .....	9
Estymatory HC .....	12
Podsumowanie .....	12

## Wstęp

Zagadnienie przyczynowości w sensie Grangera jest kluczowe w analizach finansowych. Standardowe procedury testowania opierają się z reguły na założeniu homoskedastyczności składników losowych. Jednak w przypadku danych finansowych często to założenie nie jest spełnione, gdyż szeregi cen i stóp zwrotu instrumentów finansowych mogą wykazywać efekty ARCH/GARCH. Nieuwzględnienie heteroskedastyczności może prowadzić do zafałszowania wyników z testów, a w szczególności do niepoprawnego rozmiaru testu to znaczy częstotliwości odrzucenia hipotezy zerowej w sytuacji gdy jest ona prawdziwa (popętnienie błędu pierwszego rodzaju).

Celem projektu jest analiza wpływu nieuwzględnienia heteroskedastyczności składników losowych na rozmiar testu przyczynowości Grangera w kontekście modelu VAR(1). W ramach badania oceniono skuteczność różnych estymatorów HC:

- HC0
- HC1
- HC2
- HC3

Przeprowadzając badanie skoncentrowano uwagę na wpływ parametrów takich jak:

- Długość danych
- Siła heteroskedastyczności składników losowych
- Siła autokorelacji badanych szeregów

## Przygotowanie danych oraz modelu VAR(1)

Prawidłowe przygotowanie szeregów to kluczowy element do właściwej interpretacji wyników.

$$x_t = \alpha_0 + \alpha_1 x_{t-1} + \varepsilon_{x,t}$$

$$y_t = \beta_0 + \beta_1 y_{t-1} + \varepsilon_{y,t}$$

Model autoregresji AR(1) dla zmiennych  $X_t$  oraz  $Y_t$

Początkowo wygenerowano reszty z modelu GARCH(1,1) dla równania  $X_t$  uwzględniając jednocześnie że bezwarunkowa wariancja musi być równa jeden.

$$\sigma_t^2 = \omega + \alpha \varepsilon_{x,t-1}^2 + \beta_{garch} \sigma_{t-1}^2$$

$$\mathbb{E}(\sigma_t^2) = \frac{\omega}{1 - \alpha - \beta_{garch}} = 1$$

Następnie wygenerowano równanie  $Y_t$  z modelu AR(1) z białym szumem  $N(0,1)$ . Kolejnym krokiem było wygenerowanie pełnego równania  $X_t$  wykorzystując model AR(1) z resztami z efektem GARCH. Podczas generowania szeregów w każdym przypadku celowo dodawano 1000 obserwacji aby uniknąć wpływu warunków początkowych i pozwolić parametrom ustabilizować się, pierwsze 1000 obserwacji zostało usunięte tuż przed dopasowaniem modelu VAR. Finalnie mając dwie serie  $X_t$  oraz  $Y_t$  dopasowano do nich model VAR(1).

$$\begin{cases} x_t = a_{0x} + a_{1x}x_{t-1} + a_{2x}y_{t-1} + u_{x,t} \\ y_t = a_{0y} + a_{1y}y_{t-1} + a_{2y}x_{t-1} + u_{y,t} \end{cases}$$

Model wektorowej autoregresji rzędu I - VAR(1)

W procesie nie uwzględniano wzajemnej zależności pomiędzy szeregami  $X_t$  oraz  $Y_t$  dlatego można by się spodziewać, że nie będzie występować przyczynowość.

Podczas generowania szeregów podawano różne parametry w celu sprawdzenia jak ich wartości wpływają na testowanie przyczynowości Grangera.

```
# Ustalanie parametrów
T_values = [50,100,1000]

alpha_0 = 0.0
beta_0 = 0.0

alpha1_values = [-0.8, -0.1, 0.1, 0.8] # dla AR x
beta1_values = [-0.8, -0.1, 0.1, 0.8] # dla AR y
alpha_g = 0.05 # stałe
beta_g_values = [0.1, 0.5, 0.9] # zmienne wartości beta_g

results = []
```

Pośród kluczowych parametrów znalazły się:

- **T\_values** - zmienna długość danych ( 50, 100, 1000)
- **alpha\_0, beta\_0** - stałe wyrazy wolne (alfa\_0 oraz beta\_0) w modelach AR(1) równe 0
- **alpha1\_values** - zmienny współczynnik autoregresji dla  $X_t$  w modelu AR(1) o wartościach (-0.8, -0.1, 0.1, 0.8)
- **beta1\_values** - zmienny współczynnik autoregresji dla  $Y_t$  w modelu AR(1) o wartościach (-0.8, -0.1, 0.1, 0.8)
- **alpha\_g** - stały współczynnik w modelu GARCH przy  $\varepsilon_{x,t-1}^2$  równy 0,05
- **beta\_g\_values** – zmienny współczynnik w modelu GARCH przy wariancji z poprzedniego okresu o wartościach (0.1, 0.5, 0.9)

## Badanie wpływu nie uwzględnienia heteroskedastyczności składników losowych na rozmiar testu przyczynowości Grangera w ramach modelu VAR

### **Test przyczynowości Grangera**

H0: **Brak zależności przyczynowej** w sensie Grangera zmiennej X do Y.

H1: **Występuje zależność przyczynowa** w sensie Grangera zmiennej X do Y.

Przyczynowość Grangera wskazuje na istnienie relacji predykcyjnej między zmiennymi.

Zakładamy, że hipoteza główna jest prawdziwa, co oznacza brak przyczynowości Grangera od Y do X.

$$\begin{cases} x_t = a_{0x} + a_{1x}x_{t-1} + a_{2x}y_{t-1} + u_{x,t} \\ y_t = a_{0y} + a_{1y}y_{t-1} + a_{2y}x_{t-1} + u_{y,t} \end{cases}$$


Model wektorowej autoregresji rzędu 1 - VAR(1)

W badaniach skoncentrowano się na ocenie istotności parametru  $\alpha_{2x}$  w równaniu X w modelu VAR(1).

### Wpływ długości danych

Długość danych zazwyczaj ma istotny wpływ na uzyskiwane wyniki. Wynika to przede wszystkim z większej stabilności zmiennych oraz mniejszej podatności na zakłócenia spowodowane wartościami odstającymi. W projekcie uwzględniono trzy różne długości danych:  $T = 50$ ,  $T = 100$  oraz  $T = 1000$ . Już przed rozpoczęciem analizy można przypuszczać, że najbardziej wiarygodne wyniki zostaną uzyskane przy największej wartości  $T$ .

Symulacje bez użycia estymatorów:



Można przede wszystkim zwrócić uwagę, że w przypadku najmniejszego T, wyniki odbiegają od pozostałych dwóch wartości. W przypadku badania, wartością pożądaną jest liczba odrzuceń hipotezy zerowej na poziomie 50 co daje p-value testu równe 0,05. Ważnym parametrem, który może dużo powiedzieć o wpływie długości danych na rozmiar testu jest odchylenie standardowe od wartości pożądaney. Pomimo mediany bliższej 50 dla T=100, to odchylenie wartości jest nieco mniejsze dla T=1000 czym można stwierdzić, że długość próby wpływa pozytywnie na wynik testu.

Wpływ estymatorów HC:

Więcej o estymatorach, ich strukturze oraz metodzie wyliczeń znajduje się w rozdziale poświęconym ów zagadnieniu. W przypadku analizy wpływu długości danych wyniki prezentują się następująco:

T	alpha1_x	beta1_y	beta_g	No_HC	HC0	HC1	HC2	HC3
50	-0,8	-0,8	0,1	58	88	86	68	50
100	-0,8	-0,8	0,1	55	60	60	61	67
1000	-0,8	-0,8	0,1	57	65	44	42	58

Można zwrócić uwagę na to, że ogólnie estymatory raczej wpływają w większości przypadków negatywnie na wyniki badania. Analizując, nie można stwierdzić, który estymator działa najlepiej ze względu na to, że gdy dany wariant działa dobrze dla jednej z wartości T, to w kolejnej wyniki są zupełnie przeciwne (odbiegające od wartości 50).

## Wpływ siły heteroskedastyczności składników losowych

W ramach sprawdzenia wpływu siły heteroskedastyczności składników losowych przeprowadzono badanie w którym przyporządkowano różne wartości parametru beta-g. Wynik dla różnych wartości parametrów zebrano i przedstawiono w tabelach.

$$\sigma_t^2 = \omega + \alpha \varepsilon_{x,t-1}^2 + \beta_{garch} \sigma_{t-1}^2$$

$$\mathbb{E}(\sigma_t^2) = \frac{\omega}{1 - \alpha - \beta_{garch}} = 1$$

Tabela przedstawia zbiór wyników liczby odrzuceń H0 przy zmiennym parametrze beta\_g oraz stałymi pozostałymi parametrami. Długość danych jest równa 50.

T	alpha1_x	beta1_y	beta_g	No_HC	HC0	HC1	HC2	HC3
50	-0,8	-0,8	0,1	58	88	86	68	50
50	-0,8	-0,8	0,5	75	102	72	65	55
50	-0,8	-0,8	0,9	81	70	76	71	46

Aby ułatwić interpretację i analizę wyników obliczono wartość bezwzględną z różnicy liczby odrzuceń i 50.

T	alpha1_x	beta1_y	beta_g	No_HC	HC0	HC1	HC2	HC3
50	-0,8	-0,8	0,1	8	38	36	18	0
50	-0,8	-0,8	0,5	25	52	22	15	5
50	-0,8	-0,8	0,9	31	20	26	21	4

Można zaobserwować, że wartość parametru beta\_g ma duży wpływ na liczbę odrzuceń H0. Najbardziej zadawalające wyniki znajdują się dla beta\_g=0,1 z wykorzystaniem estymatora HC3. Model najlepiej poradził sobie dla beta\_g=0,5 z wykorzystaniem HC0.

Średnie wyniki przy długości danych równej 1000 oraz zmiennych pozostałych parametrach są satysfakcjonujące.

T	beta_g	No_HC	HC0	HC1	HC2	HC3
1000	0,1	53,88	53,38	51,44	51,94	49,75
1000	0,5	53,19	51,13	53,50	49,06	50,94
1000	0,9	51,13	52,88	49,00	53,19	48,19

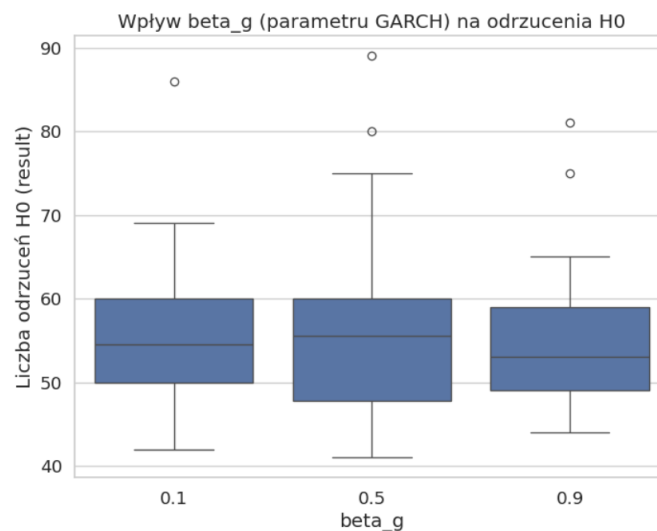
Aby ułatwić interpretację i analizę wyników ponownie obliczono wartość bezwzględną z różnicy liczby odrzuceń i 50.

		No_HC	HC0	HC1	HC2	HC3
T	beta_g	modulo -50	modulo -50	modulo -50	modulo -50	modulo -50
1000	0,1	3,88	3,38	1,44	1,94	0,25
1000	0,5	3,19	1,13	3,50	0,94	0,94
1000	0,9	1,13	2,88	1,00	3,19	1,81

Pożądana liczba odrzuceń hipotezy zerowej bliska 50 pojawia się dla modelu z wykorzystaniem parametru beta\_g o wartości 0,1 oraz estymatorem HC3. W każdym przypadku odchylenia od 50 są bardzo niewielkie.

#### *Symulacja bez użycia estymatorów HC*

Na poniższym wykresie przedstawiono wpływ parametru beta\_g w modelu GARCH na liczbę odrzuceń hipotezy zerowej (H0). Wartości beta\_g przyjmują trzy różne poziomy: 0.1, 0.5 oraz 0.9.



Mediana liczby odrzuceń  $H_0$  dla każdej z wartości  $\beta_g$  oscyluje w okolicach 50-60. Dla  $\beta_g = 0.5$  zaobserwowano większą liczbę odstających wartości powyżej 80. Wartości odstające są obecne w każdym z przypadków.



## Wpływ siły autokorelacji

Autokorelacja to miara zależności między wartościami tej samej zmiennej w różnych momentach. W kontekście modelu szeregów czasowych takich jak VAR, siła autokorelacji wskazuje jak bardzo przeszłe wartości zmiennej wpływają na jej bieżące wartości. Autokorelacja może przyjmować wartości z przedziału  $(-1,1)$ . Wyższa bezwzględna wartość współczynnika autokorelacji oznacza silniejszy związek.

Alfa<sub>1x</sub> – to siła autokorelacji w równaniu X w modelu VAR(1) [alpha1\_values]  $[-0.8, -0.1, 0.1, 0.8]$

Alfa<sub>2y</sub> – to siła autokorelacji w równaniu Y w modelu VAR(1) [beta1\_values]  $[-0.8, -0.1, 0.1, 0.8]$

W badaniu przetestowano różne wartości współczynnika autokorelacji w celu sprawdzenia jak jej wartości wpływają na moc testu przyczynowości Grangera.

Biorąc pod uwagę że przeprowadzono symulację Monte Carlo, ustalono poziom istotności alpha równy 0,05 to na 1000 iteracji kodu hipoteza zerowa powinna zostać odrzucona 50 razy. Pożądane są parametry dla których liczba odrzuceń testu jest jak najbliższa 50.

## Parametr alpha

Poniższa tabela przedstawia średnie wyniki dla różnych parametrów dobranego modelu VAR, gdzie mamy zmienny parametr alpha1\_x natomiast pozostałe parametry są stałe.

T	alpha1_x	beta1_y	beta_g	No_HC	HC0	HC1	HC2	HC3
50	-0,8	-0,8	0,1	58	88	86	68	50
50	-0,1	-0,8	0,1	60	65	69	60	40
50	0,1	-0,8	0,1	66	71	52	49	48
50	0,8	-0,8	0,1	49	59	53	53	51

Aby ułatwić interpretację i analizę wyników obliczono wartość bezwzględną z różnicy liczby odrzuceń i 50.

W kolumnach No\_HC, HC0, HC1, HC2, HC3 znajduje się bezwzględna wartość z różnicy liczby odrzuceń i 50. W takim przypadku szukamy parametru alpha1\_x dla którego liczba odrzuceń w tabeli jest bliska zeru.

T	alpha1_x	beta1_y	beta_g	No_HC	HC0	HC1	HC2	HC3
50	-0,8	-0,8	0,1	8	38	36	18	0
50	-0,1	-0,8	0,1	10	15	19	10	10
50	0,1	-0,8	0,1	16	21	2	1	2
50	0,8	-0,8	0,1	1	9	3	3	1

Najdokładniejszy wynik ukazują się dla parametru alpha1\_x równego -0,8 z wykorzystaniem HC3. Stosunkowo liczba odrzuceń hipotezy zerowej jest najbliższa 50 dla alpha1\_x równego 0,8 biorąc pod uwagę różne estymatory heteroskedastyczności.

Poniższa tabela przedstawia średnią liczbę odrzuceń przy  $T$  równym 1000 oraz zmiennych pozostałych parametrach.

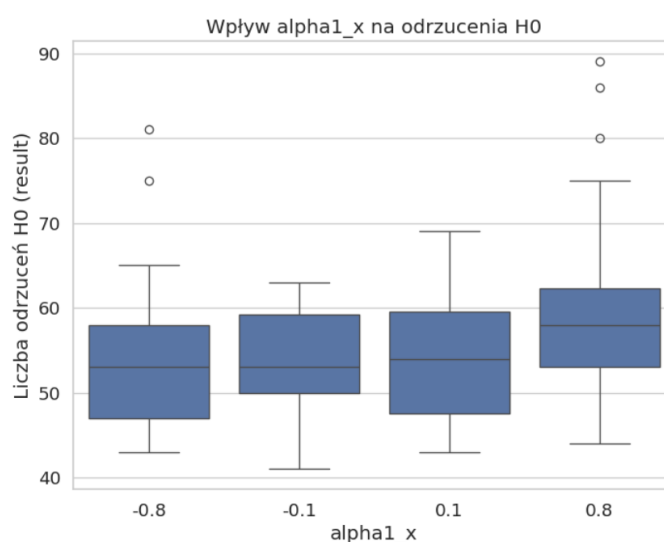
T	alpha1_x	No_HC	HC0	HC1	HC2	HC3
1000	-0,8	54,25	52,42	51,92	49,08	50,83
1000	-0,1	49,42	51,33	52,42	51,42	49,00
1000	0,1	53,25	53,92	50,25	53,08	50,75
1000	0,8	54,00	52,17	50,67	52,00	47,92

Aby ułatwić interpretację i analizę wyników obliczono wartość bezwzględną z różnicy liczby odrzuceń i 50.

		No_HC	HC0	HC1	HC2	HC3
T	alpha1_x	modulo -50	modulo -50	modulo -50	modulo -50	modulo -50
1000	-0,8	4,25	2,42	1,92	0,92	0,83
1000	-0,1	0,58	1,33	2,42	1,42	1,00
1000	0,1	3,25	3,92	0,25	3,08	0,75
1000	0,8	4,00	2,17	0,67	2,00	2,08

**Stosunkowo najlepsze wyniki pojawiły się dla  $\alpha_1 x$  równym -0,1 oraz niewykorzystaniu estymatora HC.** Największe odchylenie liczby odrzuceń hipotezy zerowej od liczby 50 można zauważyć dla  $\alpha_1 x = -0,8$  dla modelu bez wykorzystania HC. Można śmiało wyciągnąć wnioski, że wartość autokorelacji ma duży wpływ na liczbę odrzuceń hipotezy zerowej.

*Symulacja bez użycia estymatorów HC*



Wykres przedstawia wpływ wartości  $\alpha_1 x$  (siły autokorelacji w równaniu  $X$  w modelu VAR) na liczbę odrzuceń hipotezy zerowej. Widać, że mediana liczby odrzuceń dla różnych wartości  $\alpha_1 x$  jest dość stabilna i oscyluje wokół 50–60 co jest dosyć zadowalającym wynikiem. Wartości odstające pojawiają się dla  $\alpha_1 x = 0,8$  oraz  $-0,8$ , co sugeruje sporadyczne przypadki wyraźnie większej liczby odrzuceń. Wartości  $\alpha_1 x$  wpływają na liczbę odrzuceń hipotezy zerowej, ale różnice między poziomami są

stosunkowo nie duże. Na podstawie boxplotów można wywnioskować, że dodatnia bądź ujemna wartość parametru znacząco nie wpływa na liczbę odrzuceń  $H_0$ .

## Parametr beta

W tabeli przedstawiono średnie wyniki liczby odrzuceń hipotezy zerowej przy zmiennym parametrze siły autokorelacji beta oraz stały pozostałych parametrach.

T	alpha1_x	beta1_y	beta_g	No_HC	HC0	HC1	HC2	HC3
50	-0,8	-0,8	0,1	58	88	86	68	50
50	-0,8	-0,1	0,1	55	64	75	49	38
50	-0,8	0,1	0,1	50	80	64	48	43
50	-0,8	0,8	0,1	52	56	64	57	49

Aby ułatwić interpretację i analizę wyników obliczono wartość bezwzględną z różnicy liczby odrzuceń i 50.

T	alpha1_x	beta1_y	beta_g	No_HC	HC0	HC1	HC2	HC3
50	-0,8	-0,8	0,1	8	38	36	18	0
50	-0,8	-0,1	0,1	5	14	25	1	12
50	-0,8	0,1	0,1	0	30	14	2	7
50	-0,8	0,8	0,1	2	6	14	7	1

Model uzyskał najlepsze wyniki dla  $\beta = 0,1$  bez wykorzystania HC oraz dla  $\beta = -0,8$  z HC3. Biorąc pod uwagę jedynie zmianę wartości parametru beta, średnia liczba odrzuceń najbliższa 50 pojawiła się dla  $\beta = 0,8$ .

Poniższa tabela przedstawia średnią liczbę odrzuceń hipotezy zerowej przy  $T=1000$  oraz zmiennym parametrze beta

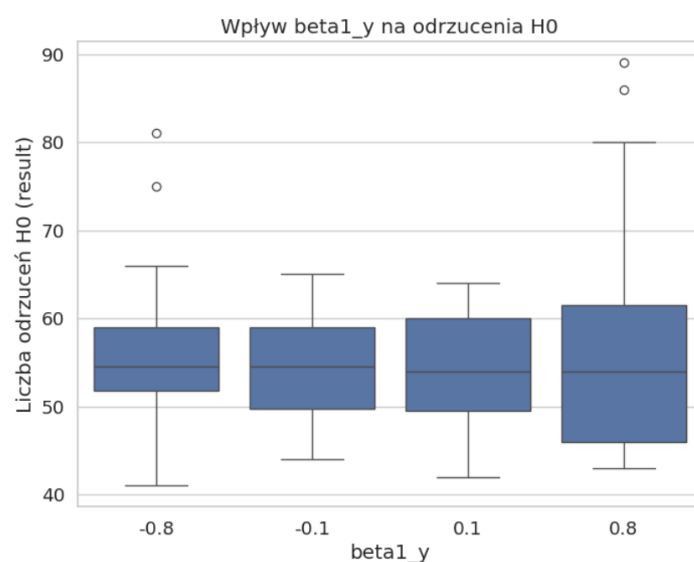
T	beta1_x	No_HC	HC0	HC1	HC2	HC3
1000	-0,8	51,58	53,42	47,42	48,33	51,08
1000	-0,1	54,67	50,75	51,17	55,42	50,08
1000	0,1	52,00	50,67	53,67	49,58	48,67
1000	0,8	52,67	55,00	53,00	52,25	48,67

Pożądane są parametry dla których liczba odrzuceń jest równa 50, ponownie aby ułatwić interpretację obliczono wartość bezwzględną z liczby odrzuceń i 50.

		No_HC	HC0	HC1	HC2	HC3
T	beta1_x	modulo -50	modulo -50	modulo -50	modulo -50	modulo -50
1000	-0,8	1,58	3,42	2,58	1,67	1,08
1000	-0,1	4,67	0,75	1,17	5,42	0,08
1000	0,1	2,00	0,67	3,67	0,42	1,33
1000	0,8	2,67	5,00	3,00	2,25	1,33

Najbardziej zadawalające wyniki ukazują się dla parametru beta równego -0,1 z wykorzystaniem estymatora HC3. Zadawalający wynik pojawia się również dla beta=0,1 z wykorzystaniem HC2. Można zaobserwować stosunkowo duże odchylenia liczby odrzuceń od 50 dla parametru beta o wartości 0,8.

#### *Symulacje bez użycia estymatorów HC*



Wykres przedstawia wpływ wartości  $\beta_{1y}$  (siły autokorelacji w równaniu Y w modelu VAR) na liczbę odrzuceń hipotezy zerowej. Mediana liczby odrzuceń dla różnych wartości  $\beta_{1y}$  jest stosunkowo stabilna i mieści się w przedziale 50-60. Wartości odstające występują przy  $\beta_{1y}=0.8$  oraz -0,8.

Podsumowując wartość współczynnika autokorelacji ma duży wpływ na liczbę odrzuceń hipotezy zerowej.

## Estymatory HC

W przypadku testu Grangera, który weryfikuje istotność parametrów krzyżowych w modelu VAR, źle ocenione błędy standardowe parametrów mogą prowadzić do fałszywych wniosków o istniejącej lub nieistniejącej przyczynowości. Aby skorygować błędy estymatorów parametrów przy występującej heteroskedastyczności stosuje się estymatory HC (heteroskedasticity-consistent covariance matrix

estimators). W kodzie zaimplementowane są cztery typy estymatorów HC: HC0, HC1, HC2, HC3. Wszystkie estymatory mają postać :

$$\text{Cov}(\hat{\beta}) = (X^T X)^{-1} X^T S X (X^T X)^{-1}$$

Gdzie macierz S jest skalowana w zależności od typu estymatora HC. Poniżej przedstawione są szczegółowe wzory każdego z tych estymatorów.

1. HC0:

$$S = \text{diag}(e_i^2)$$

**Legenda:**

- $e_i$ : Reszty z modelu dla obserwacji  $i$
- $\text{diag}(e_i^2)$ : Macierz diagonalna z kwadratami reszt na przekątnej

HC0 (Estymator White'a) – podstawowy estymator HC, uwzględnia heteroskedastyczność lecz nie koryguje on liczby stopni swobody. Estymator HC0 może być wystarczający w przypadku dużych prób, gdzie wpływ poszczególnych zmiennych jest relatywnie mały.

2. HC1:

$$S = \text{diag} \left( e_i^2 \cdot \frac{n}{n-k} \right)$$

**Legenda:**

- $e_i$ : Reszty z modelu dla obserwacji  $i$
- $n$ : Liczba obserwacji
- $k$ : Liczba parametrów w modelu
- $\frac{n}{n-k}$ : Skalowanie korekcyjne

HC1 – skaluje reszty, aby uwzględnić liczbę parametrów, często jest on stosowany w małych próbach

### 3. HC2:

$$S = \text{diag} \left( \frac{e_i^2}{1 - h_i} \right)$$

#### Legenda:

- $e_i$ : Reszty z modelu dla obserwacji  $i$
- $h_i$ : Wartości dźwigni (leverage) dla obserwacji  $i$ , obliczane jako:

$$h_i = X_i(X^T X)^{-1} X_i^T$$

HC2 – stanowi ulepszenie względem HC1, wprowadzając korektę związaną z leverage points czyli obserwacjami, które mają szczególnie duży wpływ na wyniki estymacji. Dzięki korekcie HC2 lepiej uwzględnia zmienność reszt wynikającej z obecności tych obserwacji.

### 4. HC3:

$$S = \text{diag} \left( \frac{e_i^2}{(1 - h_i)^2} \right)$$

#### Legenda:

- $e_i$ : Reszty z modelu dla obserwacji  $i$
- $h_i$ : Wartości dźwigni (leverage) dla obserwacji  $i$
- $(1 - h_i)^2$ : Kwadrat korekty na wpływ dźwigni

HC3 – estymator ten jest dalszym rozszerzeniem HC2, ponownie bierze on pod uwagę leverage points, podnosi jednak skalę korekty do kwadratu (element zastosowany w mianowniku HC2 jest podniesiony do kwadratu), w efekcie obserwacje o wysokim leverage mają jeszcze większy wpływ na korektę błędów standardowych. HC3 jest z tego powodu najczęściej zalecanym wariantem w bardzo małych próbach lub gdy istnieje silne podejrzenie, że pojedyncze obserwacje znacząco wpływają na dopasowanie modelu.

Efektem występowania heteroskedastyczności jest zwykle zniekształcenie rozmiaru.

## Analiza wyników estymatorów HC

W celu analizy wyników z przeprowadzonej symulacji Monte Carlo zdecydowaliśmy się na następującą strategię: ponieważ  $\alpha$  w teście wynosi 0,05 to na 1000 iteracji kodu powinniśmy 50 razy odrzucić  $H_0$ . Dla naszych danych obliczyliśmy wartość bezwzględną będącą odległością na skali liczbowej między liczbą 50, a liczbą odrzuceń  $H_0$ , następnie dla takich danych obliczyliśmy średnią oraz odchylenie standardowe. Wyniki są widoczne w poniższej tabelce :

Metoda	Średnia	Odchylenie Standardowe
Bez HC	7,42	6,52
HC0	13,79	11,06
HC1	9,67	8,68
HC2	8,48	8,69
HC3	6,69	5,88

Jak możemy zaobserwować, jedynie estymator HC3 skutecznie zmniejsza średnią odległość liczby odrzuceń hipotezy zerowej, w teście przyczynowości Grangera, od oczekiwanej wartości 50 przy 1000 próbach. Średnia dla HC3 wynosi 6,69, co jest najbliższe idealnej liczbie 0, podczas gdy inne estymatory HC dają wyniki o gorszej średniej i większym odchyleniu standardowym niż metoda bez HC, sugerując gorszą efektywność w kwestii rozmiaru testu. Prawdopodobnie estymator HC3 radzi sobie najlepiej z tymi danymi z uwagi na jego zdolności do lepszej korekty wpływu obserwacji o wysokiej dźwigni. Dlatego w analizach modelu VAR, gdzie heteroskedastyczność może zniekształcać wyniki testów, zastosowanie HC3 jest zalecane dla uzyskania bardziej wiarygodnych wyników. Warto tutaj zaznaczyć, że badany parametr T miał wartości 50, 100, 1000, a zatem część z symulacji była przeprowadzona na małych próbkach, dla których zgodnie z literaturą sugerują się użycie estymatora HC3. Estymator HC3 jest szczególnie skuteczny w przypadku małych próbek ponieważ wtedy efekty heteroskedastyczności i dźwigni są bardziej wyraźne.

## Podsumowanie

Podsumowując, największy wpływ na rozmiar testu przyczynowości w sensie Grangera miało, paradoksalnie, zastosowanie odpowiedniego estymatora lub jego brak. Średnia różnica między najlepszym a najgorszym estymatorem wynosiła około 7 odrzuceń na 1000 iteracji. Najlepszym estymatorem okazał się HC3, a tuż za nim uplasował się wariant bez zastosowania estymatora, przy czym średnia różnica między nimi wyniosła mniej niż jedno odrzucenie.

Analizując pozostałe parametry, takie jak heteroskedastyczność, autokorelacja oraz długość danych, wyniki były bardzo zbliżone. Największe różnice zaobserwowano w przypadku autokorelacji parametru alpha, gdzie średnia różnica między najlepszym a najgorszym wariantem wyniosła około 4 odrzucenia na 1000 iteracji. W przypadku wszystkich kombinacji, pomijając wpływ estymatorów, osiem różnych konfiguracji osiągnęło idealną średnią liczby odrzuceń na poziomie 50.